

Machine Learning and Pattern Recognition

东北大学“智能+X”新工科课程系列

机器学习与模式识别

东北大学 信息科学与工程学院
人工智能系、智能感知与机器人研究所
陈东岳



Mathematic Modelling of SVM problem

SVM问题的数学模型



CHAPTER ONE

问题原型

Prototype




一、问题原型

► 什么是线性可分问题？

- 如果平面中至少存在一条线，且所有蓝点在该线的一侧，而所有红点在另一侧，则两组是线性可分离的。

► 线性分类器的性能比较：

- 哪个分类器的性能更好？




一、问题原型

► 什么是模型的泛化能力？

- 分类器对未知数据的处理能力


► 如何根据泛化性能考虑模型设计？



一、问题原型

► SVM问题原型

- 决策面由方向参数 ω 和空间位置参数 γ 共同决定



- 决策面必须与两类的支撑向量具有相同的距离

CHAPTER ONE

数学模型

Mathematic Model



二、数学模型

► SVM约束优化问题——“三要素”

- 优化变量：决策面方程

如何定义？

- 目标函数：分类间隔（最大化）

如何计算？

- 约束条件：所有训练样本被正确分类

如何用数学形式表达？



二、数学模型

▶ 要素1：优化变量——超平面方程

- 线性决策超平面方程

$$g(x) = \omega^T x + \gamma = 0 \implies \text{参数: } \omega \text{ 和 } \gamma$$

1. $\omega = [\omega_1, \omega_2]^T$

- 控制决策面方向

2. 截距 $-\gamma/\omega_1$ 和 $-\gamma/\omega_2$


- 决定决策面位置

3. $\omega \perp g(x) = 0$

- 向量 ω 与决策面 $g(x) = 0$ 正交

4. 点 x 到决策面的距离


- $d = |g(x)| / \|\omega\|$



二、数学模型

▶ 要素2：目标函数——间隔的计算

- 分类间隔：支持向量到决策面距离的2倍



$$W = 2d$$

$$d = \frac{|\omega^T x_s + \gamma|}{\|\omega\|}$$

支持向量: x_s



二、数学模型

▶ 要素3：约束条件——基本描述

- 对方向参数向量 ω 的约束
 - 并非所有方向都能找到使训练样本被完全正确分类的决策面
- 对位置参数 γ 的约束
 - 决策超平面的位置必须是间隔区域的中心
- 方程 $d = \frac{|\omega^T x_s + \gamma|}{\|\omega\|}$ 对支撑向量 x_s 的约束
 - 支持向量到中心轴的距离为 d
 - 支撑向量的选择决定了决策超平面的方向和位置



二、数学模型

► 要素3：约束条件——约束条件的整合

- 整合三个约束条件：步骤1

- 假设每个样本有标签 y_i

$$y_i = \begin{cases} +1 & x_i \in A \text{类} \\ -1 & x_i \in B \text{类} \end{cases}$$

- 对于所有样本 x_i ，正确的决策面应该满足：

$$\begin{cases} \omega^T x_i + \gamma > 0 & \forall y_i = 1 \\ \omega^T x_i + \gamma < 0 & \forall y_i = -1 \end{cases}$$



二、数学模型

► 要素3：约束条件——约束条件的整合

- 整合三个约束条件：步骤2

- 决策面位于间隔区域的中心，所有支持向量到决策面距离为 d ；
- 其他样本到决策面距离一定大于 d ，因此有：

$$\begin{cases} \frac{\omega^T \mathbf{x}_i + \gamma}{\|\omega\|} \geq d, & \forall y_i = 1 \\ \frac{\omega^T \mathbf{x}_i + \gamma}{\|\omega\|} \leq -d, & \forall y_i = -1 \end{cases}$$

$$\text{令：} \quad \omega_d = \frac{\omega}{\|\omega\|d}, \quad \gamma_d = \frac{\gamma}{\|\omega\|d}$$

$$\begin{cases} \omega_d^T \mathbf{x}_i + \gamma_d \geq 1, & \forall y_i = 1 \\ \omega_d^T \mathbf{x}_i + \gamma_d \leq -1, & \forall y_i = -1 \end{cases}$$



二、数学模型

▶ 要素3：约束条件——约束条件的整合

- 整合三个约束条件：步骤3

- 比较两个线性方程： $\omega_d^T x + \gamma_d = 0$ (1)

$$\omega^T x + \gamma = 0 \quad (2)$$

- 其中： $\omega_d = \frac{\omega}{\|\omega\|_d}$, $\gamma_d = \frac{\gamma}{\|\omega\|_d}$ 所以：(1) 和 (2) 是同一个超平面！

- 使用 ω 和 γ 对变量 ω_d 和 γ_d 进行重命名，组合约束可以写为：

$$\begin{cases} \omega^T x_i + \gamma \geq 1, & \forall y_i = 1 \\ \omega^T x_i + \gamma \leq -1, & \forall y_i = -1 \end{cases}$$

- 将约束条件精简为统一表述： $y_i(\omega^T x_i + \gamma) \geq 1, \forall x_i$
 x_i 是支撑向量时，等号成立



二、数学模型

► 建立数学模型

- 间隔宽度 $W=2d$ 可以被简化:

$$d = \frac{|\omega^T x_s + \gamma|}{\|\omega\|} = \frac{1}{\|\omega\|}$$

- 为什么可以简化?
 - 间隔宽度由决策面方向确定
 - 决策面方向须满足约束条件;

- 目标函数的新形式:

$$\max_{\omega, \gamma} 2d \quad \Longrightarrow \quad \max_{\omega, \gamma} \frac{2}{\|\omega\|} \quad \Longrightarrow \quad \min_{\omega, \gamma} \frac{1}{2} \|\omega\|^2$$



二、数学模型

► 建立数学模型

- 线性SVM优化问题的数学描述

$$\min_{\omega, \gamma} \frac{1}{2} \|\omega\|^2$$

$$\text{s. t. } y_i(\omega^T x_i + \gamma) \geq 1, \quad i = 1, 2, \dots, N$$

- 数学模型特性
 - 目标函数为二次多项式函数，属于有约束凸优化问题
 - N 个不等式约束条件，每个训练样本 $\{x_i, y_i\}$ 对应一个约束条件；



总结



SVM数学模型

问题原型

线性分类器性能比较

泛化能力解释

提出问题原型

间隔

支持向量

提出问题

数学模型

SVM优化问题概述

优化变量

超平面方程

目标函数

间隔计算

约束条件

基本描述

多条约束条件的整合

建立数学模型

规范化数学描述

凸优化问题的提出





THANK YOU

感谢聆听

