

Machine Learning and Pattern Recognition

东北大学 “智能+X” 新工科课程系列

# 机器学习与模式识别

东北大学 信息科学与工程学院

人工智能系、智能感知与机器人研究所

陈东岳



Solving Non-linear SVM

# 非线性SVM求解

---



## CHAPTER ONE

# 非线性分类器策略

Strategy of Non-linear Classifier



# 一、非线性分类器策略

## ► 构造非线性决策面

将判别函数 $g(x)$ 从线性转化为非线性，此时决策面 $g(x) = 0$ 是特征空间中的一个超曲面

### • 新问题


- 判别函数 $g(x)$ 的非线性函数形式如何设定？
- 判别函数 $g(x)$ 的参数如何设计？
- 非线性约束条件下的优化问题如何求解？



# 一、非线性分类器策略

## ▶ 另一种思路：非线性映射

- 将所有样本非线性映射到某个高维空间
- 使训练数据的不可分问题在该空间中变成线性可分问题。



# CHAPTER TWO

# 核化SVM

Kernel SVM



## 二、核化SVM

### ► 核函数概念

- 对数据集进行非线性映射之后，原始的优化问题变为：

$$\begin{aligned} \min_{\omega, \gamma} & \frac{1}{2} \|\omega\|^2 \\ \text{s.t.} & y_i (\omega^T \phi(\mathbf{x}_i) + \gamma) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

- 拉格朗日对偶问题为：

$$\begin{aligned} \max_{\alpha} & \left[ \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \right] \\ \text{s.t.} & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m \end{aligned}$$

- 核函数：  $K(\mathbf{x}_i, \mathbf{x}_j)$

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$



## 二、核化SVM

### ► 核函数意义

- 原因：为什么将  $\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$  定义为核函数？
- 挑战：  $\phi(\mathbf{x}_i)$  很难设计，为了保证非线性映射后的线性可分性，映射后的空间维数可能会很高，甚至是无穷大。
- 技巧：由于  $\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$  项不会被单独计算，因此我们并不需要知道  $\phi(\mathbf{x}_i)$  的确切值。
- 效果：使用核函数  $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$  能够解决问题。





## 二、核化SVM

### ► 重现非线性SVM的数学模型

- 利用核函数，拉格朗日对偶问题可重写为：

$$\begin{aligned} \max_{\alpha} & \left[ \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \right] \\ \text{s. t.} & \quad \sum_{i=1}^m \alpha_i y_i = 0 \\ & \quad 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m \end{aligned}$$

- 问题的解为：

$$\begin{aligned} h(\mathbf{x}) &= \boldsymbol{\omega}^T \boldsymbol{\phi}(\mathbf{x}) + \gamma \\ &= \sum_{i=1}^m \alpha_i y_i \boldsymbol{\phi}(\mathbf{x}_i)^T \boldsymbol{\phi}(\mathbf{x}) + \gamma \\ &= \sum_{i=1}^m \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + \gamma \end{aligned}$$

使用核化SVM分类时，  
也只需要计算 $K(\mathbf{x}_i, \mathbf{x})$ ，  
不需要计算 $\boldsymbol{\phi}(\mathbf{x}_i)$



## CHAPTER THREE

# 核函数

Kernel Function



## 三、核函数

### ► 核函数的判定与选择

- 什么样的函数才是核函数？

从核函数的定义来看，函数 $K(\mathbf{x}_i, \mathbf{x}_j)$ 是核函数的充分必要条件是：

- $K(\mathbf{x}_i, \mathbf{x}_j)$ 可以写成映射函数 $\phi(\mathbf{x}_i)$ 和 $\phi(\mathbf{x}_j)$ 的内积；
- 映射函数 $\phi(\mathbf{x})$ 能够将特征向量 $\mathbf{x}$ 映射到一个新的希尔伯特空间。

**定理 4.1（核函数判定）：** 令 $\mathcal{X}$ 为输入空间，函数 $K$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 上的对称函数，当且仅当对于任意数据 $D = \{\mathbf{x}_i \in \mathcal{X} | i = 1, 2, \dots, m\}$ ，函数 $K$ 的Gram矩阵 $\mathcal{K}$ 均为半正定时，函数 $K$ 是核函数。

► 这里函数 $K$ 的Gram矩阵 $\mathcal{K}$ 定义为：

$$\mathcal{K} = \begin{bmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & \cdots & K(\mathbf{x}_1, \mathbf{x}_m) \\ \vdots & \ddots & \vdots \\ K(\mathbf{x}_m, \mathbf{x}_1) & \cdots & K(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}$$

## 三、核函数

### ► 常用核函数

#### 一些常用的核函数

- 多项式核函数:  $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j + 1)^q, q \geq 1$
- 高斯核函数:  $K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right), \sigma^2 > 0$
- Sigmoid核函数:  $K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta), \beta, \theta > 0$

#### 核函数的性质

- $K(\mathbf{x}_i, \mathbf{x}_j) = \beta_1 K_1(\mathbf{x}_i, \mathbf{x}_j) + \beta_2 K_2(\mathbf{x}_i, \mathbf{x}_j)$
- $K(\mathbf{x}_i, \mathbf{x}_j) = K_1(\mathbf{x}_i, \mathbf{x}_j) K_2(\mathbf{x}_i, \mathbf{x}_j)$
- $K(\mathbf{x}_i, \mathbf{x}_j) = g(\mathbf{x}_i) K_1(\mathbf{x}_i, \mathbf{x}_j) g(\mathbf{x}_j), \forall g(\mathbf{x})$




# 示例




## 示例——非线性SVM的应用

- 线性不可分的两类样本：蓝色 vs 红色



## 示例——非线性SVM的应用

- 使用非线性SVM算法设计分类器。
- 调用 `sklearn` 库中的 `svm.NuSVC()` 函数；
- 函数参数使用默认设置即可（高斯核函数）。
- 分类效果如下：





# 总结





## 非线性SVM求解

非线性分类器策略

构造非线性决策面  
非线性映射

核化SVM

引入核函数  
核函数的技巧  
非线性映射

核函数

核函数的判定

常用核函数

多项式核  
高斯核  
Sigmoid核

示例：非线性SVM的应用



S

M

A

R

T

THANK YOU

感谢聆听

