

Machine Learning and Pattern Recognition

东北大学 “智能+X” 新工科课程系列

机器学习与模式识别

东北大学 信息科学与工程学院

人工智能系、智能感知与机器人研究所

陈东岳



Convex Optimization-Math
Foundation

凸优化数学基础



CHAPTER ONE

几何解释

Geometric Interpretation



一、几何解释

► 有约束凸优化问题

- 问题定义

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s. t.} \quad & h(\mathbf{x}) = 0 \\ & g(\mathbf{x}) \leq 0 \end{aligned}$$


- $f(\mathbf{x})$: 目标函数
- $h(\mathbf{x}) = 0$: 等式约束条件
- $g(\mathbf{x}) \leq 0$: 不等式约束条件
- 可行解区域: 满足所有约束条件的解的集合




一、几何解释

► 有约束凸优化问题的几何解释

- 等式约束和不等式约束:



等式约束情况
 $g(x) = 0$



不等式约束情况
 $g(x) \leq 0$

- 目标函数等高线
- × 最优解
- - 可行解区域



CHAPTER TWO

拉格朗日乘子法

Lagrange Multiplier Method



二、拉格朗日乘子法

► 基本描述

- 等式约束的凸优化问题：
 - 目标函数： $f(x)$
 - 等式约束： $g(x) = 0$ ：
- 基本思想
 - 将约束条件 $g(x) = 0$ 转化为目标函数的一部分
 - 将有约束优化问题转化为无约束优化问题
- 拉格朗日乘子式

拉格朗日乘子

$$L(x, \lambda) = f(x) + \lambda g(x)$$



二、拉格朗日乘子法

► 求解

- 根据新目标函数 $L(\mathbf{x}, \lambda)$ 求取最优解 \mathbf{x}^* ：

- 目标函数

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

- 最优解

$$\frac{\partial L(\mathbf{x}, \lambda)}{\partial \mathbf{x}} = 0 \quad \longrightarrow \quad \nabla f(\mathbf{x}^*) + \lambda \nabla g(\mathbf{x}^*) = 0$$

$$\frac{\partial L(\mathbf{x}, \lambda)}{\partial \lambda} = 0 \quad \longrightarrow \quad g(\mathbf{x}^*) = 0$$



CHAPTER THREE

KKT条件

KKT Conditions



三、KKT条件

► 为什么讨论KKT条件

- KKT条件不是对可行解的约束;
- KKT条件是最优解的充分必要条件;
- 解决优化问题可以转化为寻找满足KKT条件的解的过程

► KKT条件的证明


- 情况1: 最优解 x^* 所在位置在边界 $g(x) = 0$ 上
- 情况2: 最优解 x^* 所在位置为 $g(x) < 0$ 的地方



三、KKT条件

► 情况1：最优解 x^* 在边界 $g(x)=0$ 上

$$\nabla f(x^*) + \lambda \nabla g(x^*) = 0$$

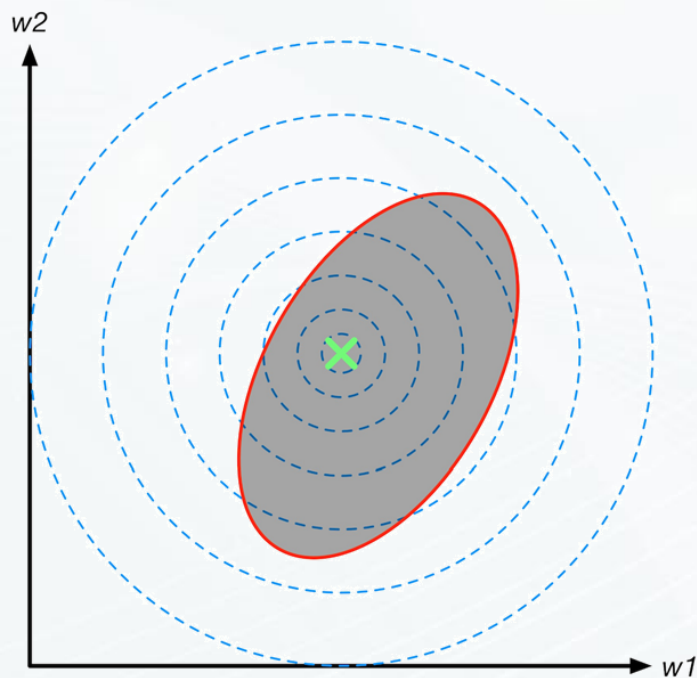


- 在最优解 x^* 附近:
可行解区域外侧, $g(x) > 0$;
可行解区域内侧, $g(x) < 0$;
 $\Rightarrow \nabla g(x)$ 指向可行解区域外侧;
- 目标函数 $f(x)$
在可行解区域外侧较小;
在可行解区域内侧较大;
 $\Rightarrow \nabla f(x)$ 指向可行解区域内侧;
 $\Rightarrow g(x^*) = 0, \lambda > 0$

三、KKT条件

► 情况2：最优解 x^* 在 $g(x) < 0$ 内

$$\nabla f(x^*) + \lambda \nabla g(x^*) = 0$$



- 最优解 x^* 在可行解的内部;
- x^* 不在边界 $g(x)=0$ 上;

$\Rightarrow \nabla f(x^*) = 0$, 约束条件不起作用

$\Rightarrow g(x^*) < 0, \lambda = 0$



三、KKT条件

► KKT条件的数学描述

情况1:
 $g(x^*) = 0, \lambda > 0$

情况 2:
 $g(x^*) < 0, \lambda = 0$

$g(x^*) \leq 0$
 $\lambda \geq 0$
 $\lambda g(x^*) = 0$

Karush-Kuhn-Tucker条件



CHAPTER FOUR

拉格朗日对偶

Lagrange Dual



四、拉格朗日对偶

► 问题转化

将有约束优化问题转化为无约束优化问题

- 原目标函数（有约束）

$$\begin{aligned} & \min_x f(x) \\ \text{s. t. } & h_i(x) = 0, i = 1, 2, \dots, m \\ & g_j(x) \leq 0, j = 1, 2, \dots, n \end{aligned}$$

- 对新目标函数的要求
 - 在可行解区域（定义为 Φ ）内与原目标函数一致
 - 在可行解区域（ Φ ）外的数值非常大，甚至无穷大



一、拉格朗日对偶

► 广义拉格朗日乘子式

$$\theta_P(\mathbf{x}) = \max_{\alpha, \beta; \beta_j \geq 0} L(\mathbf{x}, \alpha, \beta)$$

其中：

$$L(\mathbf{x}, \alpha, \beta) = f(\mathbf{x}) + \sum_{i=1}^m \alpha_i h_i(\mathbf{x}) + \sum_{j=1}^n \beta_j g_j(\mathbf{x})$$

所以：

$$\theta_P(\mathbf{x}) = \max_{\alpha, \beta; \beta_j \geq 0} L(\mathbf{x}, \alpha, \beta) = f(\mathbf{x}) + \max_{\alpha, \beta; \beta_j \geq 0} \left[\sum_{i=1}^m \alpha_i h_i(\mathbf{x}) + \sum_{j=1}^n \beta_j g_j(\mathbf{x}) \right]$$



一、拉格朗日对偶

► 广义拉格朗日乘子式

$$\theta_P(\mathbf{x}) = \max_{\alpha, \beta; \beta_j \geq 0} L(\mathbf{x}, \alpha, \beta) = f(\mathbf{x}) + \max_{\alpha, \beta; \beta_j \geq 0} \left[\sum_{i=1}^m \alpha_i h_i(\mathbf{x}) + \sum_{j=1}^n \beta_j g_j(\mathbf{x}) \right]$$

- 可行解区域内 ($\forall \mathbf{x} \in \Phi$)

$$\sum_{i=1}^m \alpha_i h_i(\mathbf{x}) = 0, \quad \sum_{j=1}^n \beta_j g_j(\mathbf{x}) \leq 0$$

$$\Rightarrow \max_{\alpha, \beta; \beta_j \geq 0} \left(\sum_{i=1}^m \alpha_i h_i(\mathbf{x}) + \sum_{j=1}^n \beta_j g_j(\mathbf{x}) \right) = 0$$

- 可行解区域外 ($\forall \mathbf{x} \notin \Phi$)

$$\sum_{i=1}^m \alpha_i h_i(\mathbf{x}) \in (-\infty, +\infty), \quad \sum_{j=1}^n \beta_j g_j(\mathbf{x}) \in [0, +\infty)$$

$$\Rightarrow \max_{\alpha, \beta; \beta_j \geq 0} \left(\sum_{i=1}^m \alpha_i h_i(\mathbf{x}) + \sum_{j=1}^n \beta_j g_j(\mathbf{x}) \right) = +\infty$$

一、拉格朗日对偶

► 问题转换结果

- 有约束优化问题

$$\begin{aligned} & \min_x f(\mathbf{x}) \\ \text{s. t. } & h_i(\mathbf{x}) = 0, i = 1, 2, \dots, m \\ & g_j(\mathbf{x}) \leq 0, j = 1, 2, \dots, n \end{aligned}$$

- 无约束优化问题

$$\min_x \theta_P(\mathbf{x}) = \min_x \left[\max_{\alpha, \beta; \beta_j \geq 0} L(\mathbf{x}, \alpha, \beta) \right]$$

$$L(\mathbf{x}, \alpha, \beta) = f(\mathbf{x}) + \sum_{i=1}^m \alpha_i h_i(\mathbf{x}) + \sum_{j=1}^n \beta_j g_j(\mathbf{x})$$

拉格朗日对偶



一、拉格朗日对偶

► 拉格朗日对偶方法

将**原始问题(Primary)**转化为**对偶问题(Dual)**进行求解

- 原始问题 $\min_x \theta_P(x) = \min_x \left[\max_{\alpha, \beta; \beta_j \geq 0} L(x, \alpha, \beta) \right]$
- 对偶问题 $\max_{\alpha, \beta; \beta_j \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha, \beta; \beta_j \geq 0} \left[\min_x L(x, \alpha, \beta) \right]$
- 原始问题与对偶问题会有相同的解吗?



一、拉格朗日对偶

► 拉格朗日对偶方法

• 定理:

- 对于原始问题和对偶问题:
- 假设函数 $f(x)$ 和不等式约束条件 $g_j(x), \forall j$ 均为凸函数,
- 等式约束条件中 $h_i(x)$ 为 x 的仿射函数 $h_i(x) = \mathbf{a}_i^T x + b_i$;
- 至少存在一个 x 使所有不等式约束条件严格成立, 即 $g_j(x) < 0, \forall j$;
- 则存在 x^*, α^*, β^* 使得 x^* 是原始问题的最优解, α^*, β^* 是对偶问题的最优解且有: $d^* = p^* = L(x^*, \alpha^*, \beta^*)$, 其充分必要条件如下:

$$\nabla_x(x^*, \alpha^*, \beta^*) = 0$$

$$\nabla_\alpha(x^*, \alpha^*, \beta^*) = 0$$

$$\nabla_\beta(x^*, \alpha^*, \beta^*) = 0$$

$$h_i(x^*) = 0, i = 1, 2, \dots, m$$

$$g_j(x^*) \leq 0, j = 1, 2, \dots, n$$

$$\beta_j^* \geq 0, j = 1, 2, \dots, n$$

$$\beta_j^* g_j(x^*) = 0, j = 1, 2, \dots, n$$



原始KKT条件


示例



例题——对偶问题求解示例

问题描述

$$\begin{aligned} \min_x f(x) &= x_1^2 + x_2^2 \\ \text{s.t. } h(x) &= x_2 - x_1 + 2 = 0 \\ g(x) &= (x_1 - 2)^2 + x_2^2 - 1 \leq 0 \end{aligned}$$



- 目标函数：二项式（凸函数）
- 等式约束：直线（线性）
- 不等式约束：圆形区域


符合拉格朗日对偶条件

例题——对偶问题求解示例

► 广义拉格朗日乘子式

$$L(\mathbf{x}, \alpha, \beta) = (x_1^2 + x_2^2) + \alpha(x_2 - x_1 + 2) + \beta[(x_1 - 2)^2 + x_2^2 - 1]$$

$$\theta_P(\mathbf{x}) = \max_{\alpha, \beta; \beta_j \geq 0} L(\mathbf{x}, \alpha, \beta)$$



$$\theta_P(\mathbf{x}) = \begin{cases} f(\mathbf{x}), & \mathbf{x} \in \Phi \\ +\infty, & \text{else} \end{cases}$$

- 可行解区域 Φ :
直线 $h(\mathbf{x}) = 0$ 与圆
 $g(\mathbf{x}) \leq 0$ 相交的弦

例题——对偶问题求解示例

► 对偶问题转化

$$\begin{aligned} \min_x f(x) &= x_1^2 + x_2^2 \\ \text{s.t. } h(x) &= x_2 - x_1 + 2 = 0 \\ g(x) &= (x_1 - 2)^2 + x_2^2 - 1 \end{aligned}$$

原始有约束
优化问题

$$\begin{aligned} \min_x \theta_P(x) &= \min_x \left[\max_{\alpha, \beta; \beta \geq 0} L(x, \alpha, \beta) \right] \\ L(x, \alpha, \beta) &= (x_1^2 + x_2^2) + \alpha(x_2 - x_1 + 2) + \beta[(x_1 - 2)^2 + x_2^2 - 1] \end{aligned}$$

原始无约束
优化问题

$$\begin{aligned} \max_{\alpha, \beta; \beta \geq 0} \theta_D(\alpha, \beta) &= \max_{\alpha, \beta; \beta \geq 0} \left[\min_x L(x, \alpha, \beta) \right] \\ L(x, \alpha, \beta) &= (x_1^2 + x_2^2) + \alpha(x_2 - x_1 + 2) + \beta[(x_1 - 2)^2 + x_2^2 - 1] \end{aligned}$$

对偶问题

例题——对偶问题求解示例

► 对偶问题求解

- 广义拉格朗日乘子式 L 对 x_1 和 x_2 分别求偏导数：

$$L(\mathbf{x}, \alpha, \beta) = (x_1^2 + x_2^2) + \alpha(x_2 - x_1 + 2) + \beta[(x_1 - 2)^2 + x_2^2 - 1]$$

$$\begin{cases} \frac{\partial L}{\partial x_1} = \alpha + 2x_1 + \beta(2x_1 - 4) = 0 \\ \frac{\partial L}{\partial x_2} = 2x_2 - \alpha + 2\beta = 0 \end{cases} \Rightarrow \begin{cases} x_1^* = \frac{4\beta - \alpha}{2\beta + 2} \\ x_2^* = \frac{\alpha}{2\beta + 2} \end{cases}$$


- 令 $\theta_D(\alpha, \beta) = \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) = L(\mathbf{x}^*, \alpha, \beta)$ ，得：

$$\theta_D(\alpha, \beta) = -\frac{\alpha^2 + 4\alpha + 2\beta^2 - 6\beta}{2(\beta + 1)}$$



例题——对偶问题求解示例

▶ 对偶问题求解



$$\theta_D(\alpha, \beta) = -\frac{\alpha^2 + 4\alpha + 2\beta^2 - 6\beta}{2(\beta + 1)}$$

$$\alpha^*, \beta^* = \underset{\alpha, \beta}{\operatorname{argmax}}(\theta_D(\alpha, \beta))$$

$$\partial \theta_D / \partial \alpha = 0, \partial \theta_D / \partial \beta = 0$$

$$\alpha^* = -2, \quad \beta^* = \sqrt{2} - 1$$



$$x_1 = \frac{4\beta - \alpha}{2\beta + 2}, x_2 = \frac{\alpha}{2\beta + 2}$$

$$x_1^* = 2 - \sqrt{2}/2, x_2^* = -\sqrt{2}/2$$



例题——对偶问题求解示例

► 拉格朗日对偶的几何解释




例题——对偶问题求解示例

► 拉格朗日对偶的几何解释

- 原始问题与对偶问题的等价解是——

广义拉格朗日乘子式的鞍点



在几何形状上看：

某个方向上：

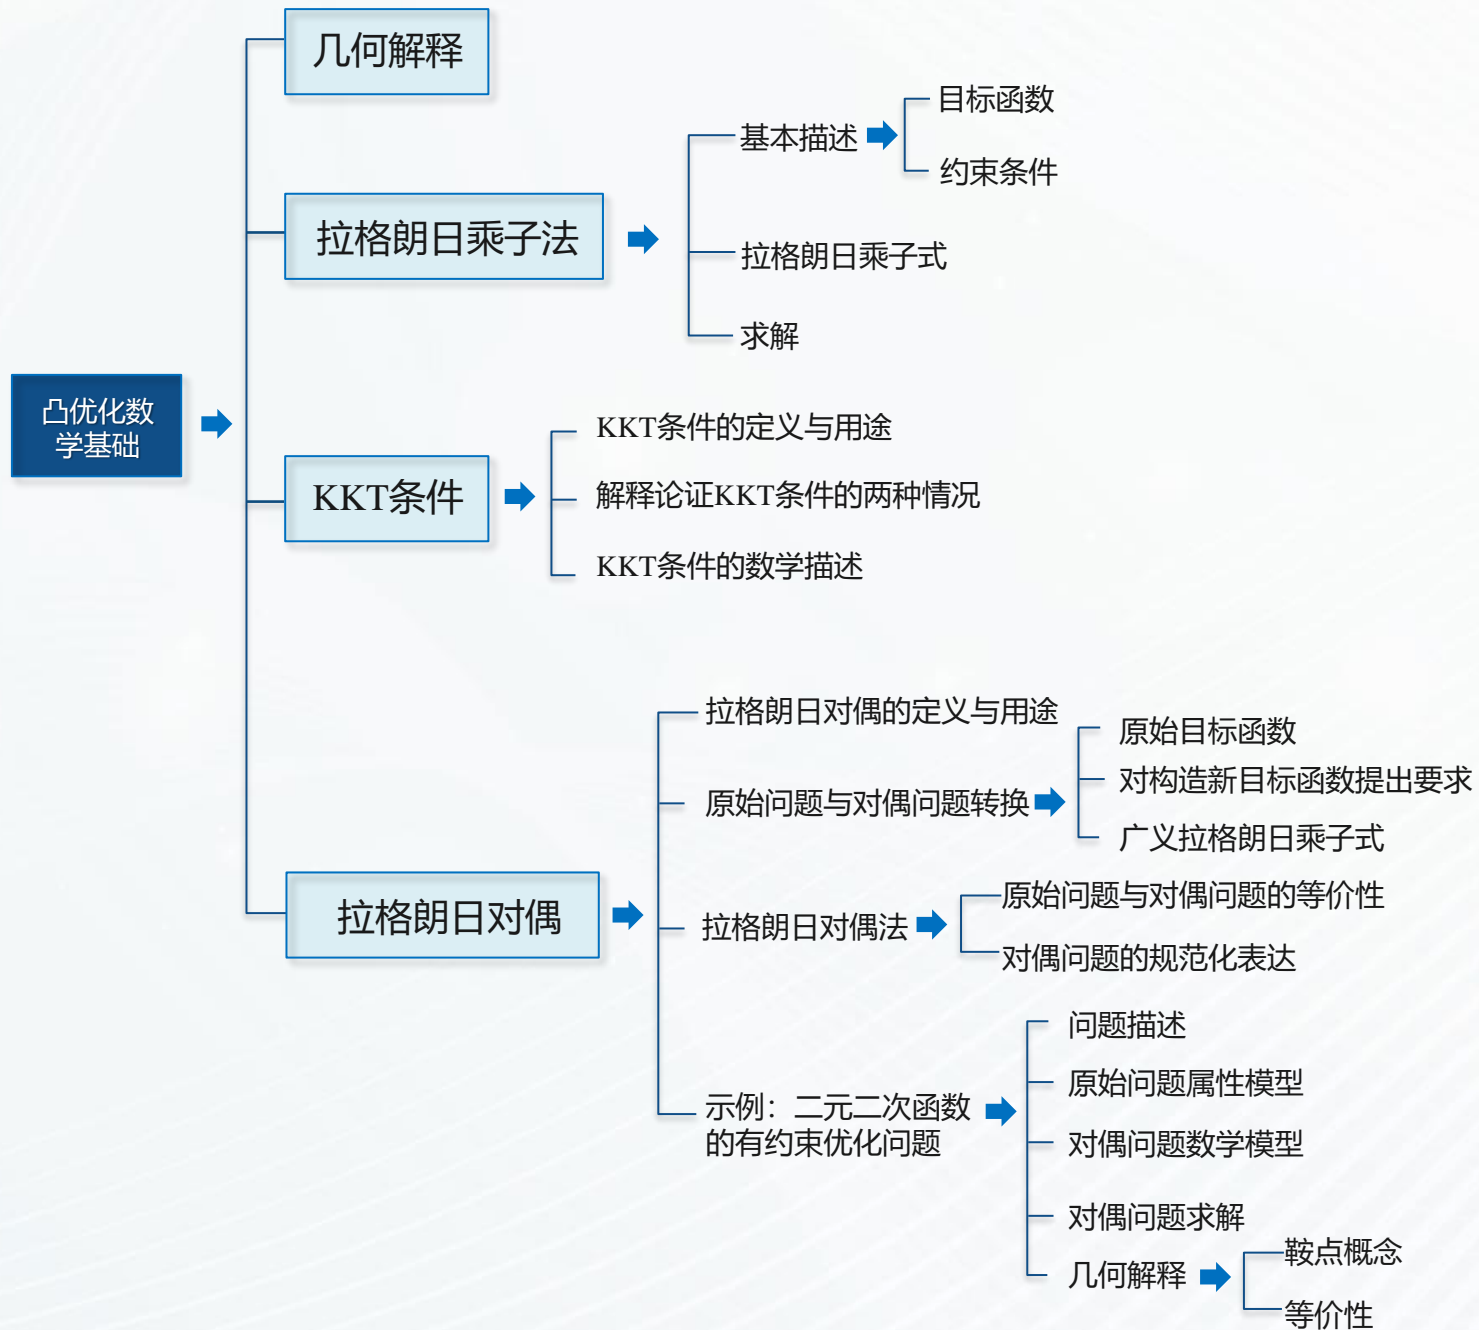
原始问题：所有最大值中的最小值；

另一方向上：

对偶问题：所有最小值中的最大值。

总结





S

M

A

R

T

THANK YOU

感谢聆听



三、分类准则

► 最大后验概率分类准则 (for多类问题)

• 分类准则

中文: 优设标题黑

思源黑体 CN Heavy 一级标题

思源黑体 CN Medium 二级标题

思源黑体 CN Normal 三级标题

英文: Times New Roman

标准字号 ≥ 22 , 内容过多字号可适当调整

公式字体: Cambria

Math

主要用色



一级标题

二级标题

三级标题



SOURCEHANSANSCN-MEDIUM.OTF



SOURCEHANSANSCN-NORMAL.OTF



SourceHanSansCN-Heavy.otf