

Machine Learning and Pattern Recognition

东北大学 “智能+X” 新工科课程系列

机器学习与模式识别

东北大学 信息科学与工程学院

人工智能系、智能感知与机器人研究所

陈东岳



Solving Linear SVM

求解线性SVM



CHAPTER ONE

SVM对偶问题推导

Derivation of SVM Dual Problem



第一节 SVM对偶问题推导

► SVM问题数学描述

$$\min_{\omega, \gamma} \frac{1}{2} \|\omega\|^2$$

$$\text{s. t. } y_i(\omega^T x_i + \gamma) \geq 1, \quad i = 1, 2, \dots, m$$

► SVM拉格朗日乘子式

$$L(\omega, \gamma, \alpha) = \frac{\|\omega\|^2}{2} + \sum_{i=1}^m \alpha_i (1 - y_i(\omega^T x_i + \gamma))$$

$$\min_{\omega, \gamma} \left[\max_{\alpha: \alpha_i \geq 0} L(\omega, \gamma, \alpha) \right] \quad \max_{\alpha: \alpha_i \geq 0} \left[\min_{\omega, \gamma} L(\omega, \gamma, \alpha) \right]$$

原始问题

对偶问题



第一节 SVM对偶问题推导

► SVM拉格朗日对偶问题求解

- 首先求解：

$$\min_{\omega, \gamma} L(\omega, \gamma, \alpha) = \min_{\omega, \gamma} \left[\frac{1}{2} \|\omega\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\omega^T \mathbf{x}_i + \gamma)) \right]$$

- 分别令函数 $L(\omega, \gamma, \alpha)$ 对 ω, γ 求偏导，并使其等于0。

$$\frac{\partial L}{\partial \omega} = \mathbf{0} \Rightarrow \omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad \frac{\partial L}{\partial \gamma} = 0 \Rightarrow 0 = \sum_{i=1}^m \alpha_i y_i$$

- 整理上式可得：

$$\begin{aligned} \min_{\omega, \gamma} L(\omega, \gamma, \alpha) &= \frac{1}{2} \left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right) + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_i \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \end{aligned}$$

第一节 SVM对偶问题推导

► 线性SVM的拉格朗日对偶问题

变形后的优化问题：

$$\max_{\alpha} \left[\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right]$$

约束条件为：

$$\sum_{i=1}^m \alpha_i y_i = 0$$
$$\alpha_i \geq 0, i = 1, 2, \dots, m$$



CHAPTER THREE

求解对偶问题

Solving Dual Problem



第三节 求解对偶问题

► 重写对偶问题

$$\max_{\alpha} \left[\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right]$$
$$s. t. \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, m$$

► 最优解必须满足原始问题的KKT条件

$$\begin{cases} \alpha_i \geq 0 \\ y_i(\boldsymbol{\omega}^T \mathbf{x}_i + \gamma) - 1 \geq 0 \\ \alpha_i(y_i(\boldsymbol{\omega}^T \mathbf{x}_i + \gamma) - 1) = 0 \end{cases}, i = 1, 2, \dots, m$$



第三节 求解对偶问题

► 如何求解最优解 α_i ——SMO算法

- 基本思路:

- 该算法以满足KKT条件为目标, 将多个变量的综合优化问题, 转化为一系列单个变量优化的迭代问题。

- 算法过程:

- 1) 随机或等值初始化 α_i , 计算 ω 和 γ ;
- 2) 挑选两个破坏KKT条件最严重的乘子 α_k 和 α_l 进行优化, 其他乘子不变;
- 3) 根据条件 $\sum_{i=1}^m \alpha_i y_i = 0$, 将 α_l 转换为 α_k 的函数;
- 4) 通过求取目标函数关于 α_k 的导数来计算 α_k 和 α_l 的封闭解;
- 5) 更新 $\alpha_k, \alpha_l, \omega$ 和 γ , 重复步骤2)和5)直到满足KKT条件, 停止。

第三节 求解对偶问题

► 如何求解最优解 α_i ——SMO算法

-1) 随机或等值初始化 α_i ，计算 ω 和 γ

$$\frac{\partial L}{\partial \omega} = \mathbf{0} \Rightarrow \omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad \alpha_i (y_i (\omega^T \mathbf{x}_i + \gamma) - 1) = 0$$



$$\omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad y_s (\omega^T \mathbf{x}_s + \gamma) - 1 = 0$$

$$S = \{i | \alpha_i > 0, i = 1, 2, \dots, m\} \quad \gamma = \frac{1}{|S|} \sum_{s \in S} [y_s - \omega^T \mathbf{x}_s]$$





第三节 求解对偶问题

► 如何求解最优解 α_i ——SMO算法

- 2) 挑选两个破坏KKT条件最严重的乘子 α_k 和 α_l 进行优化

$$\begin{cases} \alpha_i \geq 0 \\ y_i(\omega^T \mathbf{x}_i + \gamma) - 1 \geq 0 \\ \alpha_i(y_i(\omega^T \mathbf{x}_i + \gamma) - 1) = 0 \end{cases}, i = 1, 2, \dots, m$$


$$\omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$


$$\gamma = \frac{1}{|S|} \sum_{s \in S} [y_s - \omega^T \mathbf{x}_s]$$



第三节 求解对偶问题

► 如何求解最优解 α_i ——SMO算法

- 3) 根据条件 $\sum_{i=1}^m \alpha_i y_i = 0$, 将 α_l 转换为 α_k 的函数;

$$\frac{\partial L}{\partial \gamma} = 0 \Rightarrow \sum_{i=1}^m \alpha_i y_i = 0 \Rightarrow \alpha_k y_k + \alpha_l y_l = c \Rightarrow \alpha_l = y_l(c - \alpha_k y_k)$$

$$\theta_D(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$D_{k,l} = \sum_{i \neq k,l}^m \sum_{j \neq k,l}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\theta_D(\alpha) = C_{k,l} + \alpha_k + \alpha_l - \frac{1}{2} [D_k \alpha_k + D_l \alpha_l + 2\alpha_k \alpha_l y_k y_l \mathbf{x}_k^T \mathbf{x}_l + D_{k,l}]$$

$$C_{k,l} = \sum_{i \neq k,l} \alpha_i$$

$$D_k = \sum_{j \neq l} \alpha_j y_k y_j \mathbf{x}_k^T \mathbf{x}_j$$

$$D_l = \sum_{i \neq k} \alpha_i y_i y_l \mathbf{x}_i^T \mathbf{x}_l$$

第三节 求解对偶问题

► 如何求解最优解 α_i ——SMO算法

- 4)通过求取目标函数关于 α_k 的导数来计算 α_k 和 α_l 的封闭解;

➤ 求取目标函数关于 α_k 的导数

➤ 令导数为0, 求 α_k 和 α_l 的最优解

➤ $\theta_D(\alpha) = \theta_D(\alpha_k)$ 是 α_k 的二次函数, 导数 $\frac{\partial \theta_D(\alpha_k)}{\partial \alpha_k} = 0$ 具有封闭解。

➤ 将封闭解作为 $\alpha_k(t+1)$ 和 $\alpha_l(t+1)$ 数值



第三节 求解对偶问题

► 如何求解最优解 α_i ——SMO算法

- 5) 更新 $\alpha_k, \alpha_l, \omega$ 和 γ , 重复步骤2)和5)直到满足KKT条件, 停止。

➤ 在第 $t + 1$ 次迭代时, 使用新的数值 $\alpha_k(t + 1)$ 和 $\alpha_l(t + 1)$ 来代替旧的数值 $\alpha_k(t)$ 和 $\alpha_l(t)$, 更新 ω 和 γ :

$$\omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad \gamma = \frac{1}{|S|} \sum_{s \in S} [y_s - \omega^T \mathbf{x}_s]$$
$$S = \{i | \alpha_i > 0, i = 1, 2, \dots, m\}$$

➤ 终止条件即要求KKT条件在精度 ϵ 内得到满足。

$$\begin{cases} \alpha_i \geq 0 \\ y_i(\omega^T \mathbf{x}_i + \gamma) - 1 \geq 0 \\ \alpha_i(y_i(\omega^T \mathbf{x}_i + \gamma) - 1) = 0 \end{cases}, i = 1, 2, \dots, m$$

总结



线性SVM求解

对偶问题推导

- SVM原始问题描述
- SVM拉格朗日乘子式
- 求取对偶问题

对偶问题求解

- 重写对偶问题
- 讨论KKT条件
- SMO算法

- 基本思路
- 算法步骤





THANK YOU

感谢聆听

