

Machine Learning and Pattern Recognition

东北大学 “智能+X” 新工科课程系列

# 机器学习与模式识别

东北大学 信息科学与工程学院

人工智能系、智能感知与机器人研究所

陈东岳



Solving Soft Margin SVM

# 软间隔SVM求解

---



# CHAPTER ONE

# 问题模型

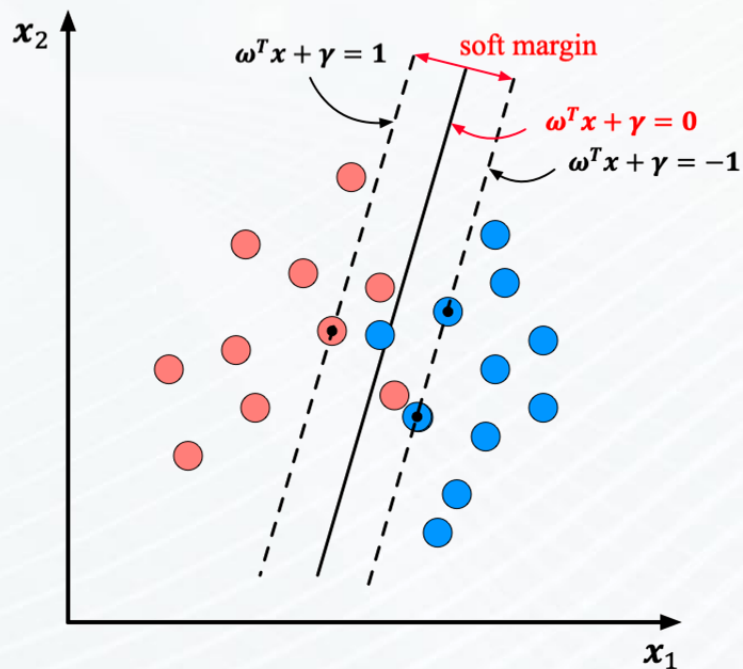
Problem model



# 一、问题模型

## ► 问题的提出——线性不可分

- 大多数分类问题是线性不可分的
- 我们需要一个允许出现分类误差的模型
- 软间隔——样本在一定程度下可以侵入到分类间隔区域内部



# 一、问题模型

## ► 代理损失(surrogate loss)

- 考虑侵入间隔区域的样本，设计一个新的损失函数。

$$\min_{\omega, \gamma} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \ell_{0/1}(y_i(\omega^T \mathbf{x}_i + \gamma) - 1)$$

- 其中：

$$\ell_{0/1}(z) = \begin{cases} 1, & \text{if } z < 0 \\ 0, & \text{otherwise} \end{cases}$$


- 然而， $\ell_{0/1}$ 不是一个足够好的选择，因为 $\ell_{0/1}$ 是不连续的、非凸的函数，因此需要具有更好数学性质的“代理损失函数”



# 一、问题模型

## ► 代理损失(surrogate loss)

- 常用的代理损失



# 一、问题模型

## ► 松弛变量的引入

$$\text{Hinge loss: } \ell_{\text{hinge}}(z) = \max(0, 1 - z)$$

- 如果采用Hinge loss, 可对每一个训练样本 $(\mathbf{x}_i, y_i)$ 引入对应的“松弛变量”  $\xi_i$ , 此时对应的优化目标为:

$$\min_{\omega, \gamma, \xi} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i$$

- 相应的约束条件变为:

$$\begin{aligned} y_i(\omega^T \mathbf{x}_i + \gamma) &\geq 1 - \xi_i \\ \xi_i &\geq 0, \quad \forall \mathbf{x}_i \end{aligned}$$


- 引入松弛变量 $\xi_i$ , 放宽了约束条件, 因此可以解决线性不可分问题。

- 思考: 目标函数中的 $C$ 起到了什么作用?

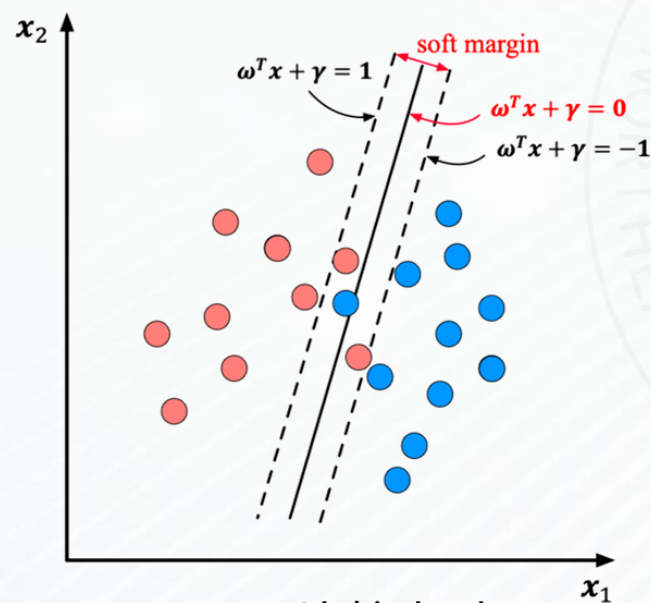


# 一、问题模型

## ▶ 惩罚系数 $C$



(1)  $C$ 比较小时



(2)  $C$ 比较大时

- $C$ 越小,  $\xi_i$ 越大 $\Rightarrow$ 间隔变大

- $C$ 越大,  $\xi_i$ 越小 $\Rightarrow$ 间隔变小



# 一、问题模型

## ► 软间隔的原始问题

- 引入松弛变量 $\xi_i$ 后, 软间隔SVM对应的优化问题可以写为:

$$\begin{aligned} \min_{\omega, \gamma, \xi} & \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s. t.} & y_i(\omega^T \mathbf{x}_i + \gamma) \geq 1 - \xi_i, \quad i = 1, 2, \dots, m \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

- 相应的拉格朗日函数为:

$$L(\omega, \gamma, \xi, \alpha, \beta) = \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i (y_i(\omega^T \mathbf{x}_i + \gamma) - 1 + \xi_i) - \sum_{i=1}^m \beta_i \xi_i$$

其中 $\alpha_i \geq 0, \beta_i \geq 0, \forall i=1, 2, \dots, m$

- 则软间隔SVM的原始问题为:

$$\min_{\omega, \gamma, \xi} \left[ \max_{\alpha, \beta: \alpha_i \geq 0, \beta_i \geq 0} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i (y_i(\omega^T \mathbf{x}_i + \gamma) - 1 + \xi_i) - \sum_{i=1}^m \beta_i \xi_i \right]$$

## CHAPTER TWO

# 问题转化

Problem transformation



## 二、问题转化

### ► 软间隔的对偶问题

- 原始问题的拉格朗日对偶问题为：

$$\max_{\alpha, \beta: \alpha_i \geq 0, \beta_i \geq 0} \left[ \min_{\omega, \gamma, \xi} L(\omega, \gamma, \xi, \alpha, \beta) \right]$$

其中

$$L(\omega, \gamma, \xi, \alpha, \beta) = \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i (y_i (\omega^T \mathbf{x}_i + \gamma) - 1 + \xi_i) - \sum_{i=1}^m \beta_i \xi_i$$

- 求 $L(\omega, \gamma, \xi, \alpha, \beta)$ 对 $\omega, \gamma, \xi$ 的极小值，令相应的偏导数为0

$$\frac{\partial L}{\partial \omega} = \mathbf{0} \Rightarrow \omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad (1)$$

$$\frac{\partial L}{\partial \gamma} = 0 \Rightarrow 0 = \sum_{i=1}^m \alpha_i y_i \quad (2)$$

$$\frac{\partial L}{\partial \xi} = \mathbf{0} \Rightarrow C - \alpha_i - \beta_i = 0, \forall i = 1, 2, \dots, m \quad (3)$$

- 将(1)(2)(3)式代入 $L(\omega, \gamma, \xi, \alpha, \beta)$ 中，可得

$$\min L(\omega, \gamma, \xi, \alpha, \beta) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

## 二、问题转化

### ► 软间隔的对偶问题

- 考虑约束条件

$$\begin{aligned} s. t. \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & C - \alpha_i - \beta_i = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, m \\ & \beta_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

- 拉格朗日对偶问题可以重写为：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ s. t. \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m \end{aligned}$$



## 二、问题转化

### ► 软间隔的KKT条件

- 软间隔SVM优化问题的KKT条件变为：

$$\left\{ \begin{array}{ll} \alpha_i \geq 0 & (1) \\ y_i f(\mathbf{x}_i) - 1 + \xi_i \geq 0 & (2) \\ \alpha_i (y_i f(\mathbf{x}_i) - 1 + \xi_i) = 0 & (3) \\ \beta_i \geq 0 & (4) \\ \xi_i \geq 0 & (5) \\ \beta_i \xi_i = 0 & (6) \end{array} \right. \quad i = 1, 2, \dots, m$$

其中:  $f(\mathbf{x}) = \boldsymbol{\omega}^T \mathbf{x} + \gamma$



## 二、问题转化

### ► KKT条件的解释

- 对于软间隔KKT条件，可以进行如下解释：


$$\begin{cases} \alpha_i \geq 0, \beta_i \geq 0 \\ 1 - \xi_i - y_i f(x_i) \leq 0 \\ \alpha_i(1 - \xi_i - y_i f(x_i)) = 0 \\ \xi_i \geq 0, \beta_i \xi_i = 0 \end{cases} \quad \begin{cases} \omega = \sum_{i=1}^m \alpha_i y_i x_i \\ 0 = \sum_{i=1}^m \alpha_i y_i \\ C = \alpha_i + \beta_i \end{cases}$$

- Case1:  $\alpha_i = 0$  , 由  $\begin{cases} C = \alpha_i + \beta_i \\ \beta_i \xi_i = 0 \end{cases} \Rightarrow \begin{cases} \beta_i = C \\ \xi_i = 0 \end{cases} \Rightarrow$  样本 $x_i$ 位于间隔之外
- Case2:  $\alpha_i > 0$  ,  $y_i f(x_i) = 1 - \xi_i$ , 样本 $x_i$ 是一个支持向量
  - 如果 $\alpha_i < C$ , 那么 $\beta_i > 0$ , 从而得知 $\xi_i = 0$ , 所以 $x_i$ 在边界上
  - 如果 $\alpha_i = C$ , 那么 $\beta_i = 0$ ,
    - 如果 $\xi_i \leq 1$ , 那么 $x_i$ 在间隔区域内正确的一侧
    - 如果 $\xi_i > 1$ , 那么 $x_i$ 被错误分类了

## 二、问题转化

### ► KKT条件的解释

- Case1:  $\alpha_i = 0, \beta_i = C, \xi_i = 0$
- Case2:  $\alpha_i > 0, y_i f(x_i) = 1 - \xi_i$ 
  - Case2-1:  $\alpha_i < C, \beta_i > 0, \xi_i = 0$
  - Case2-2:  $\alpha_i = C, \beta_i = 0,$ 
    - Case2-2-1:  $\xi_i \leq 1$
    - Case2-2-2:  $\xi_i > 1$



## CHAPTER THREE

# 模型解释

Model Explanation





## 三、模型解释

### ► 经验风险与结构风险

- 有别于软间隔SVM的几何解释，还可以对优化问题进行如下改造：

$$\min_{\omega, \gamma} \sum_{i=1}^m \ell_h(\mathbf{x}_i) + \lambda \|\omega\|^2$$

其中


$$\ell_h(\mathbf{x}) = \begin{cases} 1 - y(\omega^T \mathbf{x} + \gamma), & y(\omega^T \mathbf{x} + \gamma) < 1 \\ 0, & y(\omega^T \mathbf{x} + \gamma) \geq 1 \end{cases}, \quad \lambda = \frac{1}{2C}$$

- $\ell_h$  可以用  $\ell_{\text{exp}}$  或  $\ell_{\text{log}}$  等代理损失函数来代替， $\sum_{i=1}^m \ell_h(\mathbf{x}_i)$  被称为 **经验风险 (Empirical Risk, ER)**
- $\|\omega\|^2$  被称为 **结构风险 (Structure Risk, SR)**
- $\lambda$  用来调和ER和SR之间的矛盾。

## 三、模型解释

### ► 经验风险与结构风险


- 模型越简单，经验风险越大，结构风险越小。
- 模型越复杂，经验风险越小，结构风险越大。
- $\lambda$ 用来调和经验风险和结构风险之间的矛盾。




## 三、模型解释

### ► 过拟合与正则化


- 对于一个通用的分类器模型而言，结构化风险 $\|\omega\|^2$ 有一个更常用的称谓——正则化项（Regularization term）。
- 奥卡姆剃刀原理（Occam's Razor）：在所有能够解决当前训练数据集上的分类问题的模型假设中，我们应该选择其中最简单的一个假设。



(1)



(2)



(3)

# 总结



## 软间隔SVM求解

### 问题模型

- 问题的提出
- 引入松弛变量
- 代理损失
- 软间隔的原始问题

### 问题转化

- 软间隔的对偶问题
- 软间隔的KKT条件
- KKT条件的解释

### 模型解释

- 经验风险与结构风险
- 过拟合与正则化





THANK YOU

感谢聆听

